

Matrix Decomposition

WHAT IS A MATRIX DECOMPOSITION

La **descomposición** es una forma de **reducir** una matriz para así **simplificar** operaciones matriciales complicadas en unas más simples.

LU DECOMPOSITION

La **descomposición LU** sirve para matrices cuadradas y descompone en una matriz **L** y una **U**, donde la matriz **L** es una **matriz triangular inferior** y la matriz **U** es una **matriz triangular superior**.

Una variación es la descomposición **LUP** o descomposición LU con **pivoteo parcial**. Los filas de la matriz inicial son **reordenadas** para simplificar el proceso de descomposición y la matriz adicional especifica una forma de **permutar** el resultado para regresar al **orden original**.

Esta descomposición se puede implementar en Python tal como indica el [Ejemplo 1](#).

QR DECOMPOSITION

La **descomposición QR** es para matrices de $n \times m$ y se descompone en una matriz **Q** y una **R**, donde **Q** es una matriz de $m \times m$ y **R** es una matriz triangular superior de $m \times n$.

Esta descomposición se puede implementar en Python tal como indica el [Ejemplo 2](#).

CHOLESKY DECOMPOSITION

Esta descomposición es para matrices cuadradas simétricas donde todos los valores son mayores que cero, llamadas matrices definidas positivas. La descomposición constará del producto de una matriz triangular inferior **L** con su transpuesta L^T . También puede ser escrita como el producto de la transpuesta de una matriz triangular superior **U** ($A = U^T \cdot U$).

Esta descomposición se puede implementar en Python tal como indica el [Ejemplo 3](#).

Eigendecomposition

EIGENDECOMPOSITION OF A MATRIX

La **eigendecomposición** de una matriz descompone una matriz cuadrada en un conjunto de **eigenvectores** y **eigenvalores**.

Un vector es un **eigenvector** de una matriz si satisface la siguiente ecuación:

$$A \cdot v = \lambda \cdot v$$

Una matriz puede tener un eigenvector y un eigenvalor para cada dimensión de la matriz inicial. La matriz inicial puede ser expresada de la siguiente manera:

$$A = Q \cdot \Lambda \cdot Q^T$$

Donde **Q** es una matriz compuesta de **eigenvectores**, **Λ** es la matriz diagonal compuesta de los **eigenvalores** y Q^T es la transpuesta de la matriz **Q**.

EIGENVECTORS AND EIGENVALUES

Los **eigenvectores** son vectores unitarios y los **eigenvalores** son coeficientes aplicados a los eigenvectores que dan a los vectores su **longitud o magnitud**.

CALCULATION OF EIGENDECOMPOSITION

Podemos calcular la eigendecomposición en Python tal como indica el [Ejemplo 1](#).

CONFIRM AN EIGENVECTOR AND EIGENVALUE

Para confirmar que un vector es un eigenvector necesitamos multiplicar el eigenvector candidato por el valor del vector y comparar el resultado. Podemos implementarlo en Python como indica el [Ejemplo 2](#).

RECONSTRUCT MATRIX

Podemos reconstruir la matriz en Python como indica el [Ejemplo 3](#).

Singular Value Decomposition

WHAT IS THE SINGULAR-VALUE DECOMPOSITION

Es un método de **descomposición matricial** para simplificar los cálculos matriciales.

$$A = U \cdot \Sigma \cdot V^T$$

Donde **U** es una matriz de $m \times m$, **Σ** es una matriz diagonal de $m \times n$ y **V** es una matriz de $n \times n$.

Los valores de la diagonal de **Σ** se conocen como **valores singulares**, las columnas de **U** son llamadas **vectores singulares izquierdos** y las columnas de **V** son llamadas **vectores singulares derechos**.

CALCULATE SINGULAR-VALUE DECOMPOSITION

Esta descomposición se puede implementar en Python tal como indica el [Ejemplo 1](#).

RECONSTRUCT MATRIX

Podemos reconstruir la matriz original multiplicando **U**, **Σ** y **V**, sin embargo, en algunos casos, al pasar **Σ** a una matriz diagonal, nos quedará de dimensión $m \times m$ cuando requerimos que sea de $m \times n$ para poder multiplicarlos.

$$U_{m \times m} \cdot \Sigma_{m \times m} \cdot V_{n \times n}^T \rightarrow U_{m \times m} \cdot \Sigma_{m \times n} \cdot V_{n \times n}^T$$

Para arreglar este problema, se creará una nueva matriz **Σ** de $m \times n$ con valores cero y llenar las primeras $n \times n$ con la matriz diagonal original. Podemos reconstruir la matriz en Python como indica el [Ejemplo 2](#).

PSEUDOINVERSE

Es la **generalización** de la inversa de una **matriz cuadrada** a una **matriz rectangular**, la cual, es conocida también como la **Inversa de Moore-Penrose** y denotada por A^+ .

Podemos calcularla a través de la descomposición de valores singulares:

$$A^+ = V \cdot D^+ \cdot U^T$$

Donde D^+ es la **pseudoinversa** de la matriz diagonal **Σ** y podemos obtenerla calculando el **recíproco** de cada elemento diferente de cero de **Σ** y tomando su **transpuesta** si es que la matriz original era rectangular.

$$\Sigma = \begin{pmatrix} s_{1,1} & 0 & 0 \\ 0 & s_{2,2} & 0 \\ 0 & 0 & s_{2,2} \end{pmatrix} \rightarrow D^+ = \begin{pmatrix} \frac{1}{s_{1,1}} & 0 & 0 \\ 0 & \frac{1}{s_{2,2}} & 0 \\ 0 & 0 & \frac{1}{s_{3,3}} \end{pmatrix}$$

Podemos calcular la pseudoinversa en Python como indica el [Ejemplo 3](#).

DIMENSIONALITY REDUCTION

Para reducir la dimensión de una matriz tomamos los **k** valores singulares más grandes de **Σ** y así obtener la siguiente aproximación.

$$B = U \cdot \Sigma_k \cdot V_k^T$$

Podemos reducir la dimensión en Python como indica el [Ejemplo 4](#).